

Model Mana yang Sebenarnya Menjawab? Substitusi Model Senyap, Validator Deterministik, dan *Routing* Multi-Model dalam Agen Paper Berbasis LLM

Andi Agung Dwi Arya B
Program Studi Magister Teknik Informatika, Fakultas Teknik
Universitas Hasanuddin
Makassar, Indonesia
D082251054 · [TODO: email]

Abstrak—Kami menunjukkan bahwa label ini dapat salah: GitHub Copilot CLI menerima nama model apa pun dan, ketika akun tidak berhak atasnya, secara diam-diam menyediakan model yang berbeda—`claude-opus-4.8-fast` diminta dan `claude-haiku-4.5` menjawab, dan sebuah nama model fiktif “succeeded” juga muncul. Hanya event penggunaan dari penyedia yang menyebutkan model yang menjawab. Kami memasukkan pengamatan ini ke dalam *paper-agent*, sebuah agen sumber terbuka untuk paper ilmiah yang (i) mencatat model yang melayani setiap panggilan, (ii) mengarahkan pekerjaan ke model berdasarkan peran, dan (iii) membungkus setiap keluaran model dengan validator deterministik. Terjemahan aman struktur tersebut menyamarkan LaTeX menjadi placeholder dan tag penekanan, di mana multiset dan penempel-angka diverifikasi per unit. Pada sebuah paper IEEE delapan bagian (146 unit, 4,673 kata, 262 placeholder) kami membandingkan sebuah pipeline tiga-model (draf, sunting pasca oleh model yang berbeda, QA terjemahan balik oleh model lokal, seleksi per unit) dengan dua konfigurasi model tunggal. Pipeline dan model API tunggal keduanya mempertahankan semua 146 unit secara struktural utuh (model lokal kehilangan dua); kepatuhan glosarium pipeline (99.0%) dan cosine lintas-bahasa rata-ratanya (0.826 langsung, 0.958 terjemahan balik) *tidak* lebih tinggi daripada model tunggal (99.7%; 0.837, 0.961), dan membutuhkan waktu dinding tiga kali lipat. Nilainya adalah penangkapan kesalahan: sebuah kalimat yang tertinggal dalam bahasa Inggris, sebuah istilah teknis yang salah, dan placeholder yang berpindah sebelum angka hanya ditemukan karena model kedua membaca ulang teks dan karena validator menolak keluaran yang cacat. Tiga kelas kesalahan—placeholder yang dipindahkan, model QA yang menggemakan inputnya, dan placeholder yang hilang—tidak terdeteksi oleh model manapun, termasuk penilai, melainkan oleh validator. Kami berargumen bahwa provenans model yang melayani dan validasi deterministik seharusnya menjadi standar pada agen riset, dan bahwa tinjauan multi-model paling baik diterapkan secara selektif.

Kata Kunci—model bahasa besar, routing model, provenans, terjemahan mesin, LaTeX, sistem AI komposit, LLM-sebagai-penilai, agen riset

I. PENDAHULUAN

Perangkat lunak ilmiah yang dibangun di sekitar LLM kini secara rutin merupakan sistem *komposit*: beberapa model, komponen retrieval dan pemeriksaan berbasis aturan bekerja sama, dan pemilihan model per langkah adalah variabel desain, bukan konstanta [1]–[3]. Agen riset yang membaca,

menerjemahkan, meninjau atau meringkas makalah adalah kasus yang menonjol, dan hasil mereka masuk ke tesis dan publikasi bersama dengan pernyataan semacam “the LLM was model-X”. Pernyataan itu merupakan bagian dari catatan ilmiah: ia menentukan apakah sebuah hasil dapat direproduksi dan apakah dua run dapat dibandingkan.

Paper ini dimulai dari sebuah insiden dalam sistem semacam itu. Sebuah agen neuro-simbolik untuk mendeteksi indikator synthesis gap dalam literatur ilmiah [4] memanggil sebuah model komersial melalui GitHub Copilot SDK [5] dan memberi label setiap hasil dengan model yang dikonfigurasi, `claude-opus-4.8-fast`. Ketika hak akses akun berubah, CLI terus menerima nama itu—dan terus mengembalikan jawaban—sementara model yang berbeda, `claude-haiku-4.5`, yang melakukan pekerjaan. Tidak ada dalam respons yang menandakan substitusi model; sebuah nama model fiktif diterima dengan sama tenangnya. Satu-satunya bukti yang dapat diandalkan adalah event penggunaan yang menamai model yang menjawab. Label dalam tesis tersebut, untuk suatu periode, salah.

Insiden ini menimbulkan pertanyaan umum bagi agen riset: *model mana yang sebenarnya menjawab, dan bagaimana agen sebaiknya mengetahui, mencatat, dan memanfaatkan hal itu?* Kami mengubah pertanyaan tersebut menjadi tiga pertanyaan penelitian.

- **RQ1** Apakah model yang menjawab suatu permintaan sama dengan model yang diminta, dan mekanisme apa yang memberikan agen sebuah label provenans yang benar?
- **RQ2** Pada tugas yang sensitif terhadap struktur—menerjemahkan sebuah paper LaTeX sambil menjaga kutipan, matematika, dan silang-referensi tetap utuh—apakah sebuah pipeline yang menggabungkan beberapa model (penerjemah, penyunting, penilai) mengungguli satu model tunggal, dan dengan biaya apa?
- **RQ3** Kesalahan mana yang tertangkap oleh model (model kedua yang membaca ulang keluaran) dan mana yang hanya tertangkap oleh validator deterministik?

Kami menjawabnya dengan *agen paper*, sebuah agen sumber

terbuka untuk paper ilmiah yang setiap panggilan LLM-nya mencatat model yang menjawab, merutekan pekerjaan ke model berdasarkan peran, dan memvalidasi setiap keluaran model secara deterministik. Kontribusinya adalah:

- sebuah laporan empiris tentang substitusi model senyap dalam SDK vendor dan sebuah mekanisme provenans (pencatatan model yang melayani, peringatan substitusi, label provenans yang benar) yang kami rekomendasikan untuk agen riset;
- sebuah metode terjemahan yang aman struktur untuk LaTeX yang menyamakan perintah, matematika, dan referensi menjadi placeholder serta menempatkan penekanan ke dalam tag, memverifikasi multiset mereka dan keterikatannya pada angka per unit, dan mereproduksi sumber byte demi byte ketika tidak ada terjemahan yang diterapkan;
- perbandingan terkontrol antara sebuah pipeline tiga-model dengan dua konfigurasi model tunggal pada 146 unit yang sama, dengan metrik per-unit (cosine lintas bahasa, cosine terjemahan balik, kepatuhan glosarium, integritas struktur, waktu, model yang melayani) yang dirilis bersama kode;
- sebuah analisis kesalahan yang menunjukkan bahwa manfaat pipeline terletak pada menangkap kesalahan daripada meningkatkan rata-rata, dan bahwa tiga kelas kesalahan tidak terlihat oleh setiap model, termasuk penilai, namun tertangkap oleh validator.

Agan tersebut juga memverifikasi referensi terhadap basis data bibliografis, mengatur gerbang sitasi, membangun dan memeriksa PDF, meninjau sebuah paper dengan dua kritikus independen, dan mengonversi manuskrip Word ke IEEE LaTeX; fungsi-fungsi ini dijelaskan sebagai bagian dari sistem tetapi dievaluasi hanya secara informal di sini. Versi bahasa Indonesia dari paper ini diproduksi oleh agen itu sendiri.

II. PEKERJAAN TERKAIT

a) Sistem komposit, routing (perutean) dan ensemble: FrugalGPT menunjukkan bahwa mengkaskadiakan model murah dan mahal dapat menyamai model kuat dengan sebagian kecil biaya [2]; RouteLLM mempelajari router dari data preferensi [3]; LLM-Blender memberi peringkat dan memadukan keluaran beberapa model [6]; Mixture-of-Agents melapiskan model yang saling menyempurnakan jawaban satu sama lain [7]. Chen et al. mengamati bahwa lebih banyak pemanggilan tidak membantu secara monoton dan bahwa manfaatnya bergantung pada distribusi kesulitan tugas [1]. Pipeline kami adalah sistem komposit kecil dengan peran tetap; kontribusi kami bukan router yang lebih baik melainkan temuan bahwa nilai kombinasi pada tugas kami muncul dalam penangkapan kesalahan daripada dalam kualitas rata-rata, dan bahwa validator deterministik adalah komponen yang paling banyak menangkap.

b) Model menilai model: LLM-sebagai-penilai setuju dengan manusia pada tingkat kesepakatan antar-anotator pada tugas chat [8], dan umpan balik diri secara iteratif meningkatkan banyak tugas generasi [9], [10]. Dua temuan memperingatkan terhadap penggunaan satu model tunggal untuk menilai dirinya sendiri: LLM tidak dapat secara andal mengoreksi penalaran

sendiri tanpa sinyal eksternal [11], dan evaluator LLM mengenali serta lebih menyukai generasi mereka sendiri [12]. Oleh karena itu kami menggunakan model yang berbeda sebagai penyunting, model ketiga untuk terjemahan balik, dan tidak pernah membiarkan sebuah model menjadi penentu tunggal validitas struktural.

c) Estimasi kualitas terjemahan mesin: Metrik berbasis referensi seperti COMET [13] memerlukan referensi manusia yang tidak kami miliki; anotasi MQM oleh pakar [14] adalah standar emas tetapi mahal. Terjemahan bolak-balik telah ditinjau kembali sebagai estimator bebas referensi [15], model kelas GPT kompetitif sebagai penerjemah [16] dan merupakan evaluator terjemahan terdepan [17]. Kami menggabungkan kesamaan embedding kalimat lintas bahasa [18], [19] dengan terjemahan balik oleh model lokal [20]; terjemahan balik sebagai teknik berakar dari augmentasi data [21]. Konsistensi terminologi, yang ditegakkan dalam penerjemahan mesin neural melalui dekoding terkendali [22], ditangani di sini oleh glosarium dalam prompt dan diukur secara deterministik setelahnya.


d) Provenans dan dokumentasi model: Model cards [23] mendokumentasikan apa itu sebuah model; survei halusinasi [24] mendokumentasikan apa yang mungkin dibuat-buat olehnya. Keduanya mengandaikan bahwa sistem mengetahui model mana yang sedang digunakannya. Dokumentasi vendor mencantumkan model mana yang dapat digunakan setiap paket langganan [25] dan papan peringkat independen mengurutkannya untuk tugas ala riset [26], tetapi keduanya tidak memberitahu agen yang berjalan model apa yang disajikan kepadanya. Agen bergaya ReAct [27] yang bertindak atas hasil alat akan sama-sama bertindak berdasarkan label model yang salah; kami menambahkan model yang melayani ke jejak.

III. DESAIN SISTEM

Gambar 1 menunjukkan jalur terjemahan agen paper; perintah lain (verifikasi referensi, gerbang sitasi, membangun QA, tinjauan dua kritikus, konversi DOCX, perencanaan tugas berbahasa alami) menggunakan mesin, peran, dan log provenans yang sama. Agen tersebut adalah paket Python dengan antarmuka baris perintah dan API HTTP; setiap panggilan LLM melewati salah satu dari dua mesin, server Ollama lokal atau SDK GitHub Copilot [5].

A. Provenans model yang melayani

SDK Copilot menjalankan CLI vendor sebagai subproses dan menyediakan API sesi. Kami mengamati bahwa sesi yang dibuat dengan sembarang string `model` menjawab; ketika akun tidak berhak atas model, model lain digunakan dan tidak ada kesalahan atau bidang dalam respons yang menunjukkan hal itu. Namun, sesi tersebut memancarkan event `assistant.usage` yang bidang `model`-nya menyebut model yang menghasilkan token. Mesin berlangganan ke event ini untuk setiap panggilan, mengembalikan teks bersama dengan model yang melayani, menghitung model yang diminta dan model yang melayani secara terpisah, dan mencetak peringatan satu kali untuk setiap pasangan (model yang diminta, model



Gambar 1. Terjemahan aman struktur dalam agen paper. LaTeX disamarkan menjadi placeholder dan tag; tiga peran model (pembuatan draf, penyuntingan pasca, QA) diisi oleh model yang berbeda; validator deterministik berada di bawah setiap panggilan model dan menolak keluaran yang cacat (mencoba ulang, model cadangan (fallback), akhirnya mempertahankan sumber). Setiap panggilan mencatat model yang diminta dan model yang melayani.

yang melayani). Semua laporan yang dihasilkan oleh agen (laporan terjemahan, laporan tinjauan, ringkasan run tugas) memuat model yang melayani. Mesin lokal mencatat nama model yang dikembalikan oleh server, yang selalu merupakan model yang diminta.

B. Peran model

Pekerjaan dialokasikan kepada *peran*, bukan kepada model: DRAFT (penerjemah), REVIEW (penyunting), QA (penerjemah balik), FALLBACK, CRITIC dan CRITIC2 (peninjauan independen), PLANNER. Pengikatan default mencerminkan model-model yang dapat diakses oleh langganan Copilot paket dasar—gpt-5-mini untuk pembuatan draf, claude-haiku-4.5 untuk penyuntingan pasca dan kritik—ditambah gemma3:27b [20] lokal untuk QA, cadangan (fallback) dan kritikus kedua; pengikatan ini digantikan oleh variabel lingkungan. Dua aturan tetap: penyunting tidak pernah menjadi model pembuat draf, dan kedua kritikus tidak pernah merupakan model yang sama [11], [12].

C. Penyamaran aman struktur

Setiap baris dari file bagian LaTeX dibagi menjadi *unit* yang dapat diterjemahkan: sebuah paragraf, argumen dari `\section/\caption/\paragraph`, sebuah sel tabel (baris dipisah pada top-level &), atau sebuah `\item` body. Baris yang murni struktur (`\begin`, `\label`, `\includegraphics`, `rules`, `comments`) dipertahankan verbatim. Di dalam sebuah unit, matematika ($\dots$), sitasi, referensi, label, identifier (`\texttt`, `\textsc`), grup kurung kurawal, $\sim$, $\%$ dan setiap perintah lain beserta argumennya diganti oleh placeholder bernomor `[[n]]`; rentang yang dimaskir bersebelahan digabung menjadi satu placeholder. Perintah penekanan `\emph`, `\textbf` dan `\textit` menjadi tag inline `<k>...</k>` yang isinya tetap diterjemahkan. Pembukaan samaran membalik kedua operasi tersebut, meng-escape bare specials yang mungkin diketik model ($\%$, $\&$, $_$), menormalkan tanda kutip tipografi dan tanda hubung kembali ke LaTeX, serta mengembalikan spasi awal dan akhir unit. Penyamaran yang

diikuti pembukaan samaran tanpa penerjemahan mereproduksi setiap byte file sumber byte demi byte; ini adalah uji unit dan pemeriksaan dry-run terhadap alat. Satu lintasan deterministik akhir menulis ulang kata sebelum `\ref` (“Fig.”, “Table”, “Section”) ke dalam bahasa tujuan, karena model kadang-kadang membiarkannya tidak diterjemahkan.

D. Validator Deterministik

Setiap keluaran model untuk sebuah unit hanya diterima jika (i) multiset placeholder sama dengan multiset sumber, (ii) multiset tag sama dengan multiset sumber, dan (iii) setiap placeholder yang menempel pada angka dalam sumber (“58[[3]]” yang berarti 58%) menempel pada angka yang sama dalam keluaran (koma desimal ditoleransi). Keluaran yang ditolak dicoba ulang, kemudian dikirim ke model cadangan (fallback), dan akhirnya teks sumber dipertahankan serta unit dilaporkan sebagai tidak diterjemahkan. Terjemahan balik yang sama dengan inputnya ditolak sebagai panggilan QA yang gagal. Setelah run, kepatuhan glosarium diukur sebagai proporsi istilah sumber glosarium yang ada dalam sebuah unit yang istilah targetnya muncul dalam keluaran. Semangat yang sama mengatur perintah lain: sebuah gerbang sitasi menolak setiap kunci `\cite` yang tidak ada di bibliografi atau tidak terverifikasi dalam setidaknya dua sumber bibliografis, dan langkah build melaporkan halaman, referensi yang tidak terdefinisi dan penanda TODO yang tersisa.

E. Pipeline dan seleksi

Pipeline MULTI menjalankan DRAFT, lalu REVIEW dengan sumber dan draf (penyunting mengembalikan teks yang disempurnakan dan catatan satu baris tentang apa yang diubah), lalu QA: kedua kandidat diterjemahkan balik ke bahasa Inggris oleh model lokal dan dinilai oleh $q = \frac{1}{2}(\cos(s, t) + \cos(s, b))$, di mana s adalah sumber yang disamarkan, t kandidat dan b terjemahan baliknya, menggunakan model embedding kalimat multibahasa `paraphrase-multilingual-MiniLM-L12-v2` [19] dengan placeholder dan tag dihapus. Versi yang ditinjau

dipilih kecuali skornya lebih dari 0.02 di bawah skor draf. Pipeline SINGLE menggunakan satu model untuk pembuatan draf dan tanpa penyuntingan pasca; QA tetap dihitung sehingga konfigurasi dapat dibandingkan. Unit dikirim dalam batch sekitar 2,500 karakter sebagai JSON; dua batch dijalankan secara bersamaan.

F. Perintah Lain

verify-refs mencocokkan setiap entri dari seed yang dikurasi (judul, penulis, tahun, DOI opsional atau id arXiv) terhadap Crossref, OpenAlex, Semantic Scholar, Scopus dan arXiv; suatu entri dianggap VERIFIED ketika kesamaan judul ≥ 0.90 dan tahun ± 1 terpenuhi pada setidaknya dua sumber, DOI seed yang salah dilaporkan dan diganti, serta BibTeX diambil dari doi.org dan divalidasi terhadap seed. *review* mengirim paper yang dipipihkan ke dua kritikus dengan rubrik tetap dan menggabungkan temuan mereka, menandai isu yang diangkat oleh keduanya; setiap temuan menyertakan model yang melayani. *docx2tex* mengonversi manuskrip Word menjadi proyek IEEEtran (heading, runs, tabel, gambar, kutipan numerik, daftar referensi sebagai seed yang belum terverifikasi). *run* mengubah permintaan berbahasa alami menjadi rencana atas alat-alat ini, yang dibuat oleh model perencana atau oleh router kata kunci, dengan semua jalur dibatasi pada direktori kerja.

IV. PENGATURAN EKSPERIMENTAL

a) *Eksperimen A: substitusi (RQ1)*: Melalui Copilot SDK, dengan token akses personal yang terperinci dari akun paket dasar, kami meminta model yang akun tersebut berhak gunakan (claude-haiku-4.5, gpt-5-mini), sebuah model yang tidak berhak digunakannya (claude-opus-4.8-fast) dan sebuah nama fiktif, serta membaca model yang melayani dari event penggunaan (Bagian III-A). Perilaku tersebut ditunjukkan oleh uji otomatis pada agen yang awalnya mengalami insiden [4].

b) *Eksperimen B: konfigurasi terjemahan (RQ2)*: Materi adalah paper konferensi IEEE pendamping [4]: delapan berkas bagian, 146 unit, 4,673 kata, 262 placeholder dan 38 tag penekanan setelah penyamaran; 51 unit adalah sel tabel, 44 adalah judul bagian atau keterangan, 7 adalah butir daftar dan 44 adalah paragraf. Sasaran adalah Bahasa Indonesia formal dengan glosarium 103 istilah yang diturunkan dari tesis yang dirangkum oleh paper (mis. *synthesis gap*, *rule engine* dan *knowledge graph* tetap dalam Bahasa Inggris; *fragmentation* $\rightarrow$ *fragmentasi*). Tiga konfigurasi menerjemahkan unit yang sama dengan glosarium dan prompt yang sama (Tabel I). Setiap konfigurasi dijalankan sekali; model API dijalankan dengan sampling default vendor, model lokal pada temperature 0.2. Perangkat keras: dua NVIDIA L40S (46 GB) untuk Ollama; gemma3:27b dalam kuantisasi 4-bit.

c) *Metrik*: (i) integritas struktur: unit yang outputnya lolos validator (Bagian III-D) dan unit yang dibiarkan dalam bahasa Inggris; (ii) kepatuhan glosarium; (iii) rata-rata cosine lintas bahasa antara teks sumber dan teks akhir serta antara sumber dan terjemahan balik dari teks akhir; (iv) untuk MULTI, rasio suntingan penyunting pasca (1— kesamaan difflib antara draf

TABEL I
KONFIGURASI YANG DIBANDINGKAN DALAM EKSPERIMEN B. QA (TERJEMAHAN BALIK + COSINE) DIHITUNG UNTUK KETIGANYA.

Konfigurasi	Draf	Sunting pasca	Seleksi
MULTI	GPT-5 mini (Copilot)	Claude Haiku 4.5 (Copilot)	per unit berdasarkan skor QA
SINGLE-Haiku	Claude Haiku 4.5 (Copilot)	—	—
SINGLE-gemma3	Gemma 3 27B (local, 4-bit)	—	—

TABEL II
EKSPERIMEN A: MODEL YANG DIMINTA VERSUS MODEL YANG MELAYANI MELALUI COPILOT SDK PADA AKUN PAKET DASAR (BERHAK: CLAUDE-HAIKU-4.5, GPT-5-MINI, GPT-5.3-CODEX, GPT-4.1). TIDAK ADA PERMINTAAN YANG MENIMBULKAN KESALAHAN.

Diminta	Dilayani (assistant.usage)
claude-haiku-4.5	claude-haiku-4.5
gpt-5-mini	gpt-5-mini
claude-opus-4.8-fast	claude-haiku-4.5
nama fiktif	claude-haiku-4.5

dan teks yang ditinjau) dan hasil seleksi; (v) waktu dinding, detik-model per unit, jumlah panggilan API dan model yang melayani; (vi) kesepakatan antar konfigurasi sebagai kesamaan tingkat karakter rata-rata dari teks akhir mereka. Nilai cosine dihitung dengan model embedding yang sama untuk semua konfigurasi dan dilaporkan beserta galat bakunya.

d) *Eksperimen C: analisis kesalahan (RQ3)*: Kami memeriksa setiap unit yang validatornya terpicu, setiap unit yang skor QA-nya turun lebih dari 0.10 setelah penyuntingan pasca, catatan perubahan penyunting pasca, dan unit bernilai terendah dari setiap konfigurasi, dan mengklasifikasikan apa yang menangkap setiap kesalahan: model penyuntingan pasca, model QA, atau validator.

V. HASIL

A. Eksperimen A: Model yang melayani bukan model yang diminta

Tabel II merangkum tes substitusi. Model yang berhak dilayani sebagaimana diminta. Setiap nama yang tidak berhak—termasuk yang fiktif—diterima tanpa kesalahan dan dijawab oleh claude-haiku-4.5. Tidak ada field pada objek respons yang berbeda antara kedua kasus; hanya event penggunaan yang menamai model yang melayani. Agen yang menjadi host insiden telah memberi label pada beberapa bulan analisis dengan nama yang diminta; label-labelnya kini diturunkan dari event penggunaan, peringatan substitusi dicatat sekali per pasangan, dan endpoint kesehatan melaporkan autentikasi secara eksplisit, karena login yang kedaluwarsa sebelumnya hanya muncul sebagai hasil kosong.

B. Eksperimen B: Tiga konfigurasi, unit yang sama

Tabel III dan Gambar 2 melaporkan perbandingan. Ketiga konfigurasi menghasilkan makalah berbahasa Indonesia yang

dapat dikompilasi (sembilan halaman dibandingkan delapan dalam bahasa Inggris; nol referensi atau sitasi yang tidak terdefinisi; gerbang sitasi lulus dengan 32 kunci yang sama). Pada metrik kualitas otomatis, konfigurasi berada dalam satu galat baku satu sama lain: run Haiku 4.5 tunggal memiliki mean cosine tertinggi (0.837 direct, 0.961 terjemahan balik) dan kepatuhan glosarium (99.7%), diikuti oleh pipeline tiga-model (0.826, 0.958, 99.0%), dan model lokal berada di antara keduanya pada cosine (0.831, 0.956) tetapi terendah pada kepatuhan glosarium (97.9%). Kedua konfigurasi berbasis Copilot mempertahankan semua 146 unit tetap utuh tanpa menggunakan model cadangan (fallback), sedangkan model lokal meninggalkan dua paragraf dalam bahasa Inggris setelah output placeholder-nya gagal divalidasi dua kali. Waktu dinding berbeda sekitar faktor tiga (22 vs 7 vs 6.4 menit) dan penggunaan API berbeda sekitar faktor dua (32 vs 17 vs 0 panggilan). Teks akhir dari dua konfigurasi manapun memiliki kesamaan karakter 0.89–0.91, i.e. ketiga sistem menghasilkan bahasa Indonesia yang pada dasarnya dapat saling dipertukarkan.

a) *Apa yang dilakukan penyunting pasca:* Dalam MULTI penyunting mengubah 38 dari 146 unit (26%); rasio suntingan rata-rata atas semua unit adalah 0.017, dan atas unit yang diubah 0.067 (maksimum 0.625). Seleksi QA mempertahankan teks yang ditinjau untuk 139 unit dan draf untuk 7 (Gambar 3a); kedua kandidat terletak dekat diagonal, yaitu penyuntingan pasca jarang mengubah skor otomatis. Catatan perubahan menjelaskan koreksi terminologi dan tata bahasa: *inferred* dirender sebagai “diturunkan” (derived) dikoreksi menjadi “disimpulkan”; *show* dirender sebagai “dibuktikan” (proven) menjadi “ditunjukkan”; sebuah calque bertanda hubung “sembilan-aturan” menjadi “dengan sembilan aturan”; dan satu kalimat bahasa Inggris lengkap yang model pembuat draf dibiarkan tanpa diterjemahkan di paragraf pembuka diterjemahkan. Tidak satu pun dari ini terlihat pada rata-rata cosine.

C. Eksperimen C: Siapa Menangkap Kesalahan Mana

Tabel IV mengklasifikasikan kesalahan yang kami temukan menurut lapisan yang menangkapnya. Tiga kelas ditangkap oleh validator dan tidak oleh lapisan lain. (i) *Placeholder yang dipindahkan:* dalam run pilot, penyunting, saat “merapikan” format angka, memindahkan placeholder untuk % ke depan angka (“hanya [[3]]58” untuk “only 58%”); pemeriksaan multiset lolos, sehingga aturan menempel pada angka ditambahkan dan kini menolak keluaran semacam itu. (ii) *Terjemahan balik yang menggema:* pada 37 panggilan untuk unit pendek (33 dipenyunting dan 4 kandidat draf) model QA lokal mengembalikan teks bahasa Indonesia tanpa perubahan alih-alih bahasa Inggris; karena terjemahan balik kemudian sama dengan kandidat, cosine terjemahan balik runtuh (19 unit turun lebih dari 0.10) dan selektor keliru memilih draf untuk 25 unit yang kedua kandidatnya identik. Aturan gema mengubah ini menjadi panggilan yang gagal yang dicoba ulang, setelah itu seleksi menjadi 139/7. (iii) *Placeholder yang hilang:* model lokal sebagai satu-satunya penerjemah kehilangan placeholder pada dua paragraf meskipun dicoba ulang; tanpa model cadangan (fallback) ini tetap dalam

bahasa Inggris dan dilaporkan, yang merupakan perilaku yang benar. Kesalahan yang ditangkap oleh model bersifat semantik: sebuah kalimat tidak diterjemahkan, istilah teknis yang salah (*confounder* menjadi “perusak” (destroyer) dalam run lokal dan “perancu” atau “konfonder” di tempat lain; “stokhastisitas” salah eja), sebuah sel tabel “Union” dibiarkan dalam bahasa Inggris dan sebuah judul bagian terpotong menjadi “Kritikus lintas” dalam run single-Haiku—tiga terakhir ditemukan oleh pembacaan manusia, yang tetap menjadi lapisan akhir.

D. Jawaban atas Pertanyaan Penelitian

RQ1. Tidak: SDK vendor dapat menyajikan model yang berbeda dari yang diminta tanpa kesalahan apa pun, dan satu-satunya label yang benar adalah model yang disebutkan dalam event penggunaan (usage event); agen mencatatnya untuk setiap panggilan. **RQ2.** Pipeline tiga model tidak meningkatkan kualitas rata-rata—satu model kuat menandingi atau melampauinya dalam sepertiga waktu—dan integritas struktur merupakan sifat dari validator daripada pipeline (kedua konfigurasi Copilot mencapai 146/146); yang ditambahkan pipeline adalah koreksi terhadap kesalahan semantik yang tidak ditunjukkan oleh metrik mana pun. **RQ3.** Kesalahan struktural dan protokol (placeholder, gema) hanya ditangkap oleh validator; kesalahan semantik ditangkap oleh model kedua atau oleh manusia.

VI. DISKUSI


a) *Rata-rata versus penangkapan kesalahan:* Ketiga konfigurasi secara statistik tidak dapat dibedakan pada metrik otomatis, dan model tunggal yang kuat adalah cara termurah untuk mencapai tingkat tersebut. Seandainya kami hanya mengevaluasi berdasarkan mean cosine, kami akan menyimpulkan bahwa pipeline multi-model adalah upaya yang sia-sia. Tinjauan per-unit mengatakan sebaliknya: integritas struktur berasal dari validator (kedua konfigurasi Copilot mencapai 146/146, model lokal 144/146), dan penyunting pada pipeline memperbaiki kesalahan semantik—sebuah kalimat yang tidak diterjemahkan, tiga istilah yang salah—yang tidak dicatat oleh metrik karena sebuah kalimat yang dibiarkan dalam bahasa Inggris masih memiliki embedding yang mirip dengan sumbernya. Hal ini sesuai dengan pengamatan bahwa manfaat panggilan LLM tambahan bergantung pada di mana kesalahan berada, bukan pada berapa banyak panggilan yang dilakukan [1]: untuk sebuah dokumen di mana sebagian besar unit sudah diterjemahkan dengan baik, model kedua sebagian besar setuju (108 dari 146 unit tidak berubah) dan membenarkan biayanya pada beberapa unit yang diubahnya.

b) *Validator adalah lapisan termurah dan satu-satunya yang melihat tiga kelas kesalahan:* Placeholder yang dipindahkan, terjemahan balik yang menggemakan, dan placeholder yang hilang tidak dapat dideteksi oleh model yang membaca teks yang lancar, dan model penilai itu sendiri merupakan sumber salah satunya. Pemeriksaan kesetaraan himpunan, ekspresi reguler untuk placeholder yang menempel pada angka, dan perbandingan string menangkap ketiganya dengan biaya yang sangat kecil. Ini adalah pelajaran yang sama yang memotivasi sistem pendamping [4], di mana lapisan aturan simbolik


TABEL III

EKSPERIMEN B PADA 146 UNIT (4,673 KATA). NILAI COSINE ADALAH RATA-RATA DARI TEKS AKHIR DENGAN GALAT BAKU; INTEGRITAS = UNIT YANG LOLOS VALIDATOR TANPA BERALIH KEMBALI KE BAHASA INGGRIS.

Metrik	MULTI	SINGLE-Haiku	SINGLE-gemma3
Integritas (unit)	146/146	146/146	144/146
Kepatuhan glosarium	284/287 (99.0%)	286/287 (99.7%)	281/287 (97.9%)
Cosine EN↔ID	0.826 ± 0.011	0.837 ± 0.011	0.831 ± 0.011
Cosine EN↔terjemahan balik	0.958 ± 0.006	0.961 ± 0.005	0.956 ± 0.007
Unit dengan teks berbahasa Inggris yang tertinggal	1 (klaim yang dikutip)	0	2
Waktu dinding (s)	1,334	425	384
Detik-model per unit (draf + sunting pasca)	7.2 + 5.0	3.0	2.8
Panggilan Copilot (model yang melayani)	16 gpt-5-mini + 16 claude-haiku-4.5	17 claude-haiku-4.5	0



Gambar 2. Eksperimen B: kualitas teks akhir (cosine dengan galat baku), kepatuhan glosarium, dan waktu dinding dari tiga konfigurasi.



Gambar 3. MULTI pipeline: (a) skor QA per unit dari draf dan dari teks hasil penyuntingan pasca dengan kandidat yang dipilih; (b) distribusi rasio suntingan penyunting atas 38 unit yang diubah.

memvalidasi keluaran LLM: sebuah LLM-sebagai-penilai [8] harus dinilai juga, dan penilai terakhir sebaiknya deterministik ketika sifatnya formal. Hal ini juga menyarankan desain untuk penggunaan produksi—*review selektif*: jalankan satu model kuat dengan validator pada setiap unit, dan kirim ke model kedua hanya unit yang diberi tanda oleh validator atau heuristik murah (cosine rendah, kata fungsi bahasa sumber yang tersisa, istilah glosarium yang terlewat, placeholder yang berulang). Pada data kami, filter semacam itu akan mengarahkan sekitar sepersepuluh hingga seperempat unit, mendekati biaya model tunggal dengan kemampuan pipeline dalam menangkap kesalahan.

c) *Model lokal untuk pemrosesan massal, model API untuk pass akhir*: Model lokal 27B adalah yang tercepat, tidak memiliki kuota, dan mencapai 97.9% kepatuhan glosarium, tetapi ia menghapus placeholder pada dua paragraf dan menghasilkan satu-satunya istilah teknis yang jelas salah. Dalam pipeline yang dilayaninya, mode kegagalannya berbiaya rendah: terjemahan balik untuk QA (di mana sebuah gema terdeteksi secara deterministik) dan cadangan (fallback). Model mana yang mengisi peran mana harus mengikuti hak akses (entitlement) akun dan profil kesalahan tugas, oleh karena itu peran, bukan nama model, adalah unit konfigurasi.

d) *Provenans*: Tanpa membaca event penggunaan (usage event), paper ini akan melaporkan pekerjaan Haiku sebagai

TABEL IV

EKSPERIMEN C: KELAS KESALAHAN DAN LAPISAN YANG MENANGKAPNYA
(P = MODEL PENYUNTINGAN PASCA, Q = MODEL QA, V = VALIDATOR
DETERMINISTIK, H = PEMBACAAN MANUSIA).

Kesalahan	Ditangkap oleh	Kejadian
Placeholder dipindahkan sebelum angka	V	1 unit (pilot)
Model QA menggemakan inputnya	V	37 panggilan
Placeholder hilang (model lokal)	V	2 unit
Kalimat tidak diterjemahkan	P	1 unit
Istilah teknis yang salah	P, H	4 istilah
Salah eja ("stokhastisitas")	H	1 unit
Sel atau judul bagian dibiarkan/terpotong	H	2 unit (Haiku)

milik Opus. Model yang diminta adalah nilai konfigurasi; model yang melayani adalah sebuah pengamatan, dan hanya pengamatan yang masuk dalam catatan ilmiah. Kami merekomendasikan agar agen riset (i) mencatat model yang melayani per panggilan, (ii) memberi label pada keluaran dengannya, (iii) memperingatkan jika terjadi substitusi model, dan (iv) memperlakukan kegagalan autentikasi sebagai kegagalan kesehatan alih-alih sebagai hasil kosong. Model cards [23] menjelaskan model; agen tetap harus menentukan kartu mana yang berlaku.

VII. KETERBATASAN

Setiap konfigurasi dijalankan sekali; keluaran LLM bervariasi antara run [4], dan perbedaan yang kami laporkan antar-konfigurasi (sekitar 0.01 pada cosine) berada dalam rentang variabilitas tersebut. Semua metrik kualitas bersifat otomatis; cosine lintas bahasa dan cosine terjemahan balik adalah proksi yang diketahui melewatkan kesalahan terminologi dan kelancaran [14], [15], yang memang merupakan area di mana penyuntingan pasca bertindak—evaluasi manusia oleh pakar domain bilingual diperlukan untuk mengkuantifikasi manfaat tersebut. Satu pasangan bahasa, satu jenis dokumen, dan satu glosarium dipelajari. Perbandingan ini mengaburkan pemilihan model dengan peran penyuntingan pasca: validator aktif pada semua konfigurasi, sehingga hasil struktural mengisolasi mereka, tetapi satu lintasan penyuntingan pasca oleh model yang sama dengan draf tidak diuji. Model QA juga berfungsi sebagai model cadangan (fallback), sehingga kelemahan sistematis dari gemma3:27b akan memengaruhi dua peran. Eksperimen A berkaitan dengan satu SDK vendor dan satu paket langganan pada satu titik waktu; perilaku dapat berubah, dan penyedia lain mungkin menolak model yang tidak dikenal. Review dua-kritikus dan konverter DOCX adalah bagian dari agen yang dirilis namun tidak dievaluasi di sini.

VIII. KESIMPULAN

Kami mendokumentasikan bahwa SDK vendor dapat secara diam-diam melayani model yang berbeda dari yang diminta dan mengubah event penggunaan yang mengungkapkannya menjadi mekanisme provenans untuk agen riset. Di sekitarnya kami membangun paper-agent, yang merutekan tugas penanganan

paper ke model berdasarkan peran dan memvalidasi setiap keluaran model secara deterministik. Dalam perbandingan terkontrol pada 146 unit LaTeX, pipeline tiga model tidak mengungguli satu model pada kualitas rata-rata maupun pada integritas struktur—kedua metrik tersebut berasal dari para validator—tetapi pipeline itu memperbaiki kesalahan semantik yang tidak terlihat oleh metrik; para validator menangkap tiga kelas kesalahan yang tidak terdeteksi oleh model mana pun, termasuk penilai. Penelitian lanjutan adalah evaluasi manusia terhadap koreksi penyunting, filter yang dipelajari untuk review selektif, dan memperluas provenans model yang melayani ke SDK lain. Sebagai pemeriksaan akhir agen menerjemahkan paper ini ke dalam Bahasa Indonesia dengan pipeline yang sama (122 unit, 4,140 kata; 122/122 unit tetap utuh secara struktural; kepatuhan glosarium 96.6%; cosine 0.867 langsung dan 0.961 terjemahan balik; model yang melayani gpt-5-mini, claude-haiku-4.5 dan gemma3:27b); kedua versi dapat dikompilasi dari bibliografi yang sama. Kode, metrik per-unit dan kedua versi bahasa dirilis di <https://github.com/devnolife/paper-agent>.

DAFTAR PUSTAKA

- [1] L. Chen, J. Q. Davis, B. Hanin, P. D. Bailis, I. G. Stoica, M. Zaharia, and J. Zou, "Are More LLM Calls All You Need? Towards Scaling Laws of Compound Inference Systems," 2024, arXiv:2403.02419.
- [2] L. Chen, M. Zaharia, and J. Zou, "FrugalGPT: How to Use Large Language Models While Reducing Cost and Improving Performance," 2023, arXiv:2305.05176.
- [3] I. Ong, A. Almahairi, V. Wu, W.-L. Chiang, T. Wu, J. E. Gonzalez, M. W. Kadous, and I. G. Stoica, "RouteLLM: Learning to Route LLMs with Preference Data," 2024, arXiv:2406.18665.
- [4] A. A. D. A. B., "A Neuro-Symbolic Agentic Approach for Detecting Synthesis-Gap Indicators in Scientific Literature," Unpublished manuscript, Universitas Hasanuddin, 2026.
- [5] GitHub, "GitHub Copilot SDK for Python (github-copilot-sdk)," <https://github.com/github/copilot-sdk>, 2026, version 1.0.x, accessed Oct. 2026.
- [6] D. Jiang, X. Ren, and B. Y. Lin, "LLM-Blender: Ensembling Large Language Models with Pairwise Ranking and Generative Fusion," in *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Association for Computational Linguistics, 2023, pp. 14 165–14 178, doi: 10.18653/v1/2023.acl-long.792.
- [7] J. Wang, J. Wang, B. Athiwaratkun, C. Zhang, and J. Zou, "Mixture-of-Agents Enhances Large Language Model Capabilities," 2024, arXiv:2406.04692.
- [8] L. Zheng, W.-L. Chiang, Y. Sheng, S. Zhuang, and Z. Wu, "Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena," 2023, arXiv:2306.05685.
- [9] A. Madaan, N. Tandon, P. Gupta, S. Hallinan, and L. Gao, "Self-Refine: Iterative Refinement with Self-Feedback," 2023, arXiv:2303.17651.
- [10] N. Shinn, F. Cassano, A. Gopinath, K. Narasimhan, and S. Yao, "Reflexion: language agents with verbal reinforcement learning," 2023, arXiv:2303.11366.
- [11] J. Huang, X. Chen, S. R. Mishra, H. Zheng, A. W. Yu, X. Song, and D. Zhou, "Large Language Models Cannot Self-Correct Reasoning Yet," 2023, arXiv:2310.01798.
- [12] A. Panickssery, S. Bowman, and S. Feng, "LLM Evaluators Recognize and Favor Their Own Generations," 2024, arXiv:2404.13076.
- [13] R. Rei, C. Stewart, A. C. Farinha, and A. Lavie, "COMET: A Neural Framework for MT Evaluation," in *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Association for Computational Linguistics, 2020, pp. 2685–2702, doi: 10.18653/v1/2020.emnlp-main.213.
- [14] M. Freitag, G. Foster, D. Grangier, V. Ratnakar, Q. Tan, and W. Macherey, "Experts, Errors, and Context: A Large-Scale Study of Human Evaluation for Machine Translation," *Transactions of the Association for Computational Linguistics*, vol. 9, pp. 1460–1474, 2021, doi: 10.1162/tacl_a_00437.

- [15] J. Moon, H. Cho, and E. L. Park, "Revisiting Round-Trip Translation for Quality Estimation," in *Proceedings of the 22nd Annual Conference of the European Association for Machine Translation*, 2020.
- [16] A. Hendy, M. Abdelrehim, A. Sharaf, V. Raunak, M. Gabr, H. Matsushita, Y. J. Kim, M. Afify, and H. H. Awadalla, "How Good Are GPT Models at Machine Translation? A Comprehensive Evaluation," 2023, arXiv:2302.09210.
- [17] T. Kocmi and C. Federmann, "Large Language Models Are State-of-the-Art Evaluators of Translation Quality," 2023, arXiv:2302.14520.
- [18] N. Reimers and I. Gurevych, "Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks," in *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*. Association for Computational Linguistics, 2019, pp. 3980–3990, doi: 10.18653/v1/d19-1410.
- [19] —, "Making Monolingual Sentence Embeddings Multilingual using Knowledge Distillation," in *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Association for Computational Linguistics, 2020, pp. 4512–4525, doi: 10.18653/v1/2020.emnlp-main.365.
- [20] G. Team, A. Kamath, J. Ferret, S. Pathak, N. Vieillard, R. Merhej, S. Perrin, T. Matejovicova, A. Ramé, M. Rivière, L. Rouillard, T. Mesnard, G. Cideron, J.-b. Grill, S. Ramos, E. Yvinec, M. Casbon, E. Pot, I. Penchev, G. Liu, F. Visin, K. Kenealy, L. Beyer, X. Zhai, A. Tsitsulin, R. Busa-Fekete, A. Feng, N. Sachdeva, B. Coleman, Y. Gao, B. Mustafa, I. Barr, E. Parisotto, D. Tian, M. Eyal, C. Cherry, J.-T. Peter, D. Sino-palnikov, S. Bhupatiraju, R. Agarwal, M. Kazemi, D. Malkin, R. Kumar, D. Vilar, I. Brusilovsky, J. Luo, A. Steiner, A. Friesen, A. Sharma, A. Sharma, A. M. Gilady, A. Goedeckemeyer, A. Saade, A. Feng, A. Kolesnikov, A. Bendebury, A. Abdagic, A. Vadi, A. György, A. S. Pinto, A. Das, A. Bapna, A. Miech, A. Yang, A. Paterson, A. Shenoy, A. Chakrabarti, B. Piot, B. Wu, B. Shahriari, B. Petrini, C. Chen, C. L. Lan, C. A. Choquette-Choo, C. Carey, C. Brick, D. Deutsch, D. Eisenbud, D. Cattle, D. Cheng, D. Paparas, D. S. Sreepathihalli, D. Reid, D. Tran, D. Zelle, E. Noland, E. Huizenga, E. Kharitonov, F. Liu, G. Amirkhanyan, G. Cameron, H. Hashemi, H. Klimczak-Plucińska, H. Singh, H. Mehta, H. T. Lehari, H. Hazimeh, I. Ballantyne, I. Szpektor, I. Nardini, J. Pouget-Abadie, J. Chan, J. Stanton, J. Wieting, J. Lai, J. Orbay, J. Fernandez, J. Newlan, J.-y. Ji, J. Singh, K. Black, K. Yu, K. Hui, K. Vodrahalli, K. Greff, L. Qiu, M. Valentine, M. Coelho, M. Ritter, M. Hoffman, M. Watson, M. Chaturvedi, M. Moynihan, M. Ma, N. Babar, N. Noy, N. Byrd, N. Roy, N. Momchev, N. Chauhan, N. Sachdeva, O. Bunyan, P. Botarda, P. Caron, P. K. Rubenstein, P. Culliton, P. Schmid, P. G. Sessa, P. Xu, P. Stanczyk, P. Tafti, R. Shivanna, R. Wu, R. Pan, R. Rokni, R. Willoughby, R. Vallu, R. Mullins, S. Jerome, S. Smoot, S. Girgin, S. Iqbal, S. Reddy, S. Sheth, S. Pöder, S. Bhatnagar, S. R. Panyam, S. Eiger, S. Zhang, T. Liu, T. Yacovone, T. Liechty, U. Kalra, U. Evci, V. Misra, V. Roseberry, V. Feinberg, V. Kolesnikov, W. Han, W. Kwon, X. Chen, Y. Chow, Y. Zhu, Z. Wei, Z. Egyed, V. Cotruta, M. Giang, P. Kirk, A. Rao, K. Black, N. Babar, J. Lo, E. Moreira, L. G. Martins, O. Sanseviero, L. Gonzalez, Z. Gleicher, T. Warkentin, V. Mirrokni, E. Senter, E. Collins, J. Barral, Z. Ghahramani, R. Hadsell, Y. Matias, D. Sculley, S. Petrov, N. Fiedel, N. Shazeer, O. Vinyals, J. Dean, D. Hassabis, K. Kavukcuoglu, C. Farabet, E. Buchatskaya, J.-B. Alayrac, R. Anil, Dmitry, Lepikhin, S. Borgeaud, O. Bachem, A. Joulin, A. Andreev, C. Hardin, R. Dadashi, and L. Hussenot, "Gemma 3 Technical Report," 2025, arXiv:2503.19786.
- [21] R. Sennrich, B. Haddow, and A. Birch, "Improving Neural Machine Translation Models with Monolingual Data," in *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Association for Computational Linguistics, 2016, pp. 86–96, doi: 10.18653/v1/p16-1009.
- [22] G. Dinu, P. Mathur, M. Federico, and Y. Al-Onaizan, "Training Neural Machine Translation to Apply Terminology Constraints," in *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*. Association for Computational Linguistics, 2019, pp. 3063–3068, doi: 10.18653/v1/p19-1294.
- [23] M. Mitchell, S. Wu, A. Zaldivar, P. Barnes, L. Vasserman, B. Hutchinson, E. Spitzer, I. D. Raji, and T. Gebru, "Model Cards for Model Reporting," in *Proceedings of the Conference on Fairness, Accountability, and Transparency*, ser. FAT* '19. ACM, Jan. 2019, pp. 220–229, doi: 10.1145/3287560.3287596.
- [24] Z. Ji, N. Lee, R. Frieske, T. Yu, D. Su, Y. Xu, E. Ishii, Y. J. Bang, A. Madotto, and P. Fung, "Survey of Hallucination in Natural Language Generation," *ACM Computing Surveys*, vol. 55, no. 12, pp. 1–38, Mar. 2023, doi: 10.1145/3571730.
- [25] GitHub Docs, "Supported AI models in GitHub Copilot," <https://docs.github.com/en/copilot/reference/ai-models/supported-models>, 2026, accessed 3 Oct. 2026.
- [26] Artificial Analysis, "Artificial Analysis: Independent LLM Evaluations (Intelligence Index, Terminal-Bench-Science, AA-Omniscience, AA-LCR)," <https://artificialanalysis.ai/evaluations>, 2026, accessed 3 Oct. 2026.
- [27] S. Yao, J. Zhao, D. Yu, N. Du, I. Shafran, K. Narasimhan, and Y. Cao, "ReAct: Synergizing Reasoning and Acting in Language Models," 2022, arXiv:2210.03629.