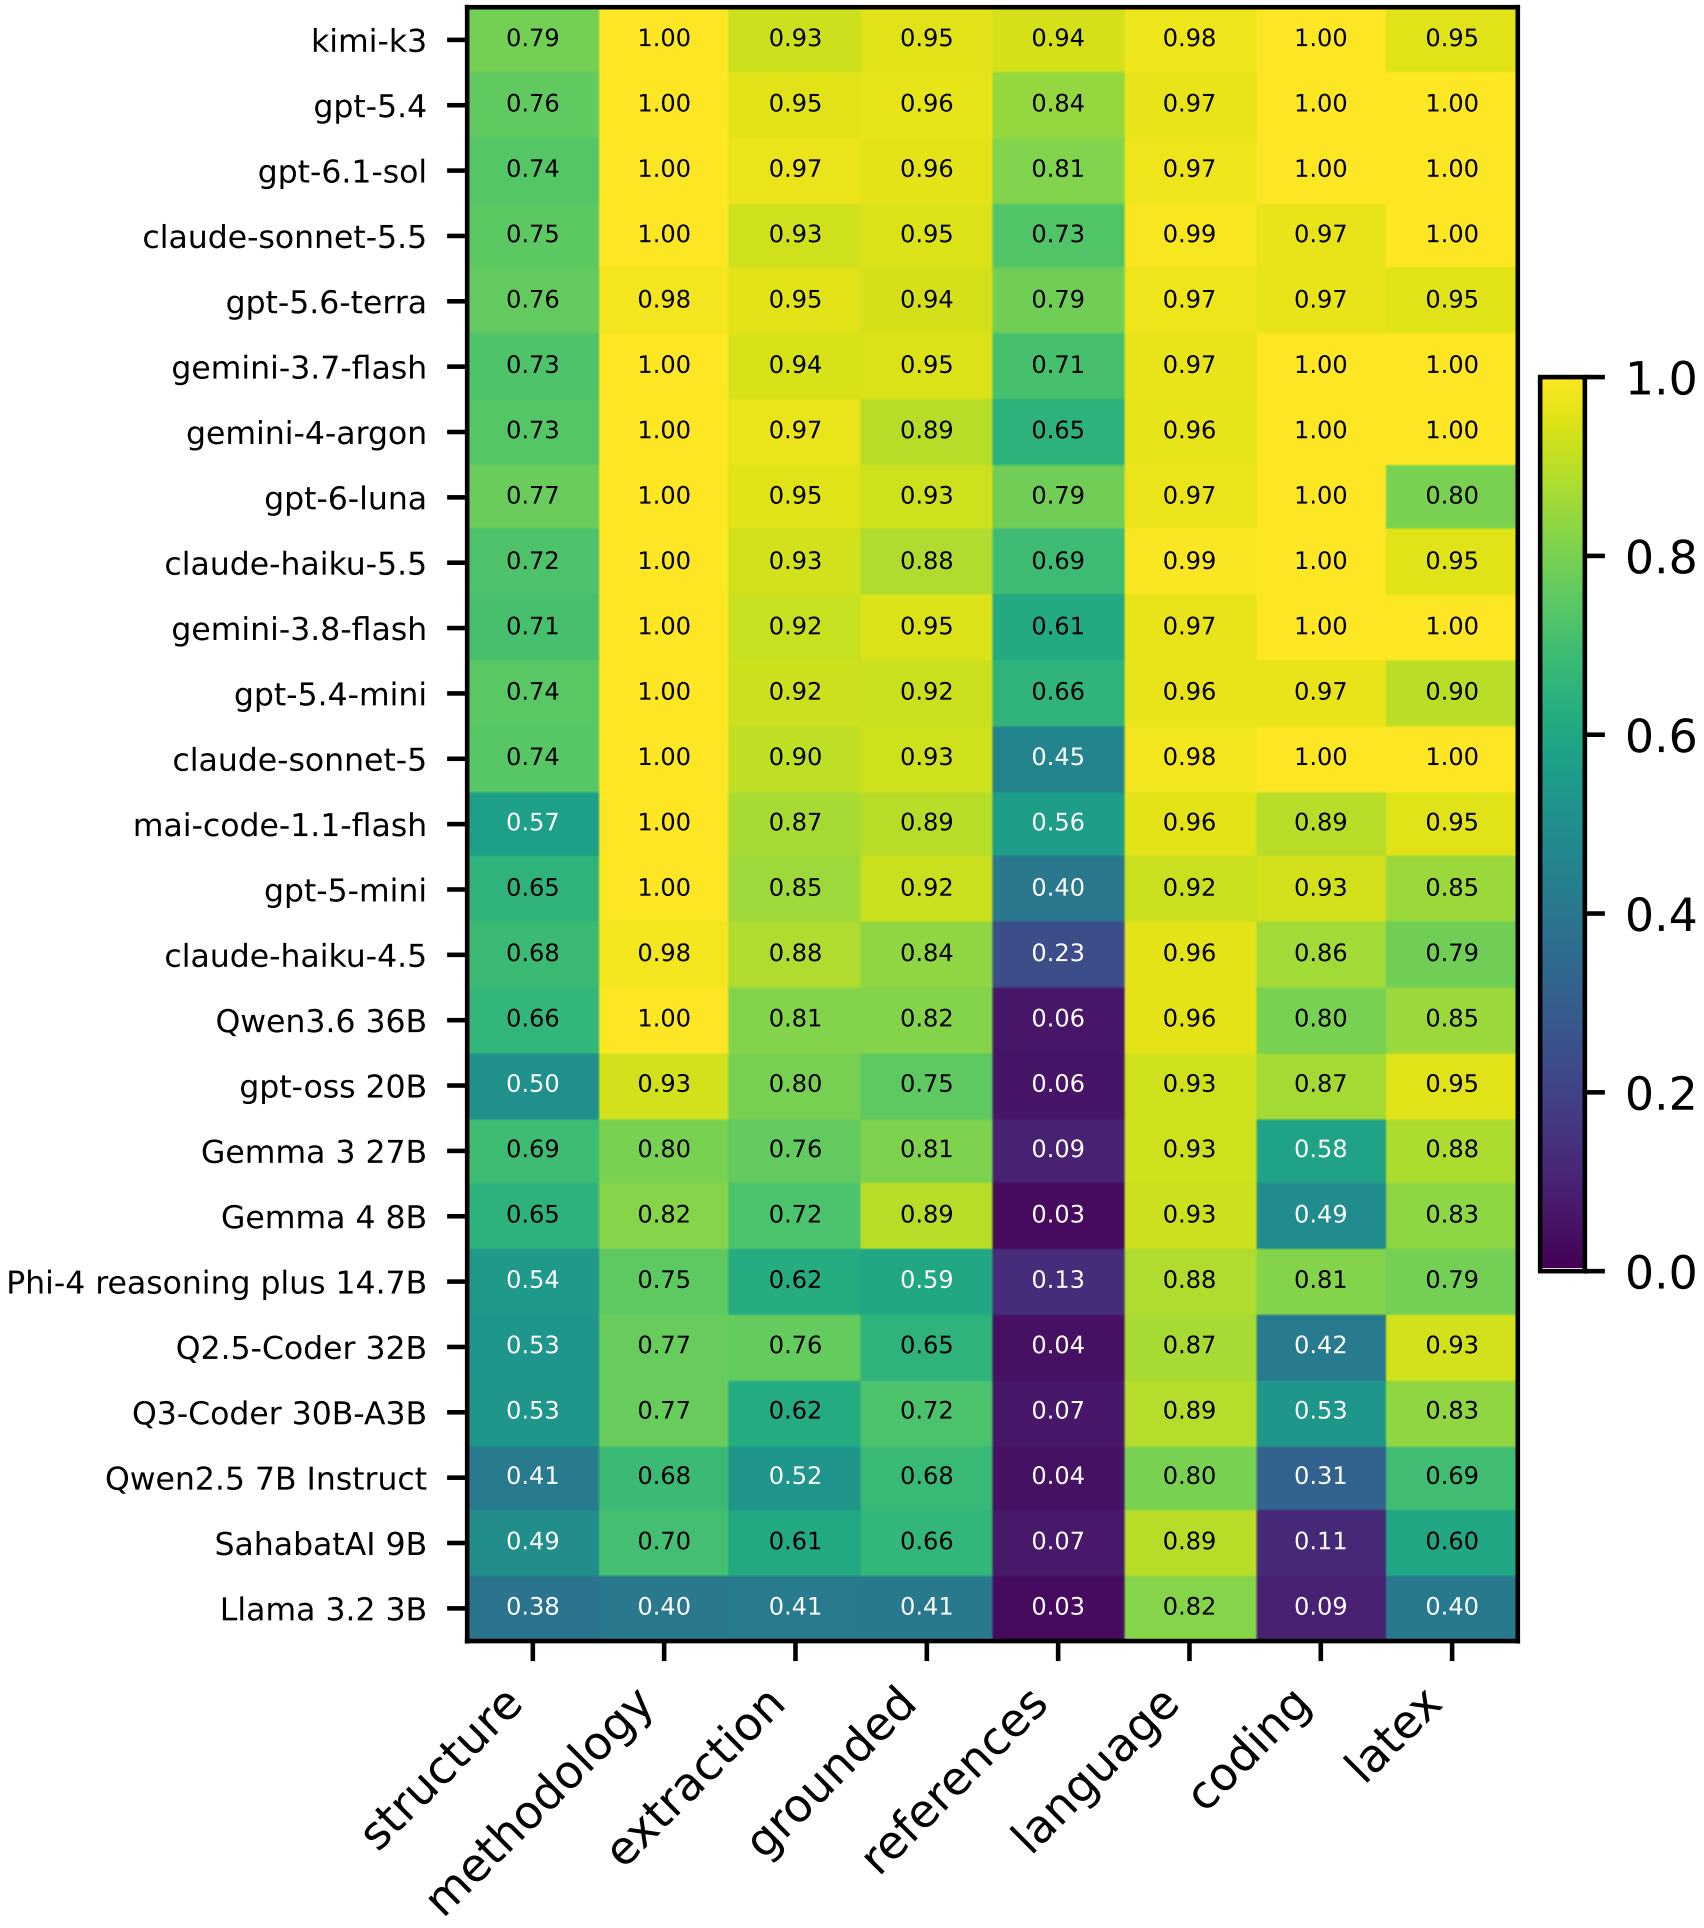
kimi-k3 0.79 1.00 0.93 0.95 0.94 0.98 1.00 0.95
gpt-5.4 0.76 1.00 0.95 0.96 0.84 0.97 1.00 1.00
gpt-6.1-sol 0.74 1.00 0.97 0.96 0.81 0.97 1.00 1.00
claude-sonnet-5.5 0.75 1.00 0.93 0.95 0.73 0.99 0.97 1.00
gpt-5.6-terra 0.76 0.98 0.95 0.94 0.79 0.97 0.97 0.95
gemini-3.7-flash 0.73 1.00 0.94 0.95 0.71 0.97 1.00 1.00
gemini-4-argon 0.73 1.00 0.97 0.89 0.65 0.96 1.00 1.00
gpt-6-luna 0.77 1.00 0.95 0.93 0.79 0.97 1.00 0.80
claude-haiku-5.5 0.72 1.00 0.93 0.88 0.69 0.99 1.00 0.95
gemini-3.8-flash 0.71 1.00 0.92 0.95 0.61 0.97 1.00 1.00
gpt-5.4-mini 0.74 1.00 0.92 0.92 0.66 0.96 0.97 0.90
claude-sonnet-5 0.74 1.00 0.90 0.93 0.45 0.98 1.00 1.00
mai-code-1.1-flash 0.57 1.00 0.87 0.89 0.56 0.96 0.89 0.95
gpt-5-mini 0.65 1.00 0.85 0.92 0.40 0.92 0.93 0.85
claude-haiku-4.5 0.68 0.98 0.88 0.84 0.23 0.96 0.86 0.79
Qwen3.6 36B 0.66 1.00 0.81 0.82 0.06 0.96 0.80 0.85
gpt-oss 20B 0.50 0.93 0.80 0.75 0.06 0.93 0.87 0.95
Gemma 3 27B 0.69 0.80 0.76 0.81 0.09 0.93 0.58 0.88
Gemma 4 8B 0.65 0.82 0.72 0.89 0.03 0.93 0.49 0.83
Phi-4 reasoning plus 14.7B 0.54 0.75 0.62 0.59 0.13 0.88 0.81 0.79
Q2.5-Coder 32B 0.53 0.77 0.76 0.65 0.04 0.87 0.42 0.93
Q3-Coder 30B-A3B 0.53 0.77 0.62 0.72 0.07 0.89 0.53 0.83
Qwen2.5 7B Instruct 0.41 0.68 0.52 0.68 0.04 0.80 0.31 0.69
SahabatAI 9B 0.49 0.70 0.61 0.66 0.07 0.89 0.11 0.60
Llama 3.2 3B 0.38 0.40 0.41 0.41 0.03 0.82 0.09 0.40
structure
methodology
extraction
grounded
references
language
coding
latex
1.0
0.8
0.6
0.4
0.2
0.0